

Análisis, Conservación y Seguimiento de Especies de Aves y Mamíferos de España

Proyecto de Ingeniería de Datos — MITECO

dbt + Snowflake

Arquitectura Medallion

Power BI

Python + GitHub

Stack: dbt Fusion 2.0 · Snowflake · dbt_utils · Power BI · Python · GitHub Actions

Autor:
Ramón García Jiménez



El encargo del MITECO

Ministerio para la Transición Ecológica · Proyecto de monitoreo de biodiversidad

“Necesitamos saber qué especies hay, dónde están y cómo evolucionan. Hay fondos europeos en juego.”

MITECO — Unidad de Biodiversidad



Control de avistamientos a través de api

Detectar avistamientos fuera de zonas protegidas y verificar patrones de distribución.



Censos y predicción

Seguimiento de poblaciones por especie y provincia. Detectar declives antes de que sean críticos.



Diversidad ecológica por CCAA

Índices Shannon & Simpson por comunidad autónoma para justificar subvenciones de la UE.

El dominio en 1 minuto

Solo España · Mammalia y Aves · Fuente: iNaturalist + censos oficiales



Especie

Nombre científico + nombre común. Cada especie tiene Familia → Clase (Mammalia / Aves).

Ej: *Lynx pardinus* → Felidae → Mammalia



Avistamiento

Observación georeferenciada de iNaturalist. Tiene fecha, coordenadas GPS y estado de verificación.



Área Protegida

Zona con figura de protección:

- LIC (Lugar de Interés Comunitario)
- ZEPA (Aves)
- Parque Nacional



Censo

Conteo oficial de individuos por especie, provincia y año. Permite calcular tendencias de población.



Amenaza + CITES

Cada especie tiene tipo de amenaza (hábitat, furtivismo) y apéndice CITES que regula su comercio.




Estado conservación

Código IUCN: LC (Preocupación menor), NT (Casi amenazada), VU (Vulnerable), EN (En peligro), CR (En peligro crítico). Ej: Lince ibérico: CR (2002) → EN (2015) → VU (2024).

Arquitectura Medallion con dbt + Snowflake

Bronze → Silver (stg + mix) → Gold (marts) · Imagen: DAG real del proyecto



Capa Bronze — Fuentes raw

4 tablas en Snowflake + 3 seeds · Sin transformar · Incluye ruido internacional

FUENTES RAW

avistamientos.areas

Áreas protegidas + bounding box GPS

avistamientos.observaciones

Obs. iNaturalist — incluye Marruecos, Portugal...

especies.catalogo

Catálogo taxonómico con estados IUCN

especies.censos

Censos oficiales por provincia y año

seed: provincia_ccaa

Mapa provincia → CCAA

seed: estado_conservacion

Códigos IUCN con nivel de riesgo

seed: tipo_amenaza

Catálogo de amenazas

PROBLEMAS EN BRUTO



Registros internacionales

iNaturalist incluye observaciones de Marruecos, Portugal y Gibraltar. Filtro WHERE país = 'SPAIN'.



Todas las clases taxonómicas

El catálogo tiene Reptilia, Insecta... Solo nos interesan Mammalia y Aves. Filtro WHERE iconic_taxon_name IN (...).



Fechas en múltiples formatos

DD/MM/YYYY, YYYY/MM/DD, YYYY-MM-DD mezclados. COALESCE + TRY_TO_DATE con los tres formatos.



Valores negativos en censos

Errores de exportación Excel generan 0 y -1 como 'sin dato'. Macro custom positive_values los detecta.



Inconsistencias de texto

Mayúsculas, tildes, espacios: 'Andalucia' vs 'Andalucía'. TRIM + LOWER + REPLACE en Silver.



Sin PKs claras en censos

No hay ID único en censos — se identifica por (especie, año, provincia, entidad). Surrogate key MD5.

iNaturalist permite corregir observaciones

El usuario puede cambiar la especie de un avistamiento ya publicado → necesitamos MERGE, no INSERT ni APPEND.

El problema:

Un observador registra un avistamiento como 'Aquila chrysaetos' (Águila real) y más tarde lo corrige a 'Aquila fasciata' (Águila de Bonelli).

Con un INSERT puro, tendríamos dos registros del mismo avistamiento con especies distintas.

Solución:

Modelo incremental con estrategia MERGE.
La PK es id_avistamiento — si existe, actualiza; si es nuevo, inserta.

CONFIGURACIÓN EN dbt

```
{{ config(
  materialized='incremental',
  unique_key='id_avistamiento',
  incremental_strategy='merge',
  on_schema_change='fail'
)}}

-- Preview CTE
with obs as (
  select *
  from {{ ref('stg_avistamientos_observaciones') }}

  {% if is_incremental() %}
    where fecha > (
      select dateadd('hour', -1, coalesce(max(fecha), '2020-01-01'::date))
      from {{ this }}
    )
  {% endif %}
),
```

- **unique_key = id_avistamiento**

Snowflake ejecuta MERGE INTO: actualiza si existe, inserta si es nuevo.

- **Ventana -1 hora**

iNaturalist puede entregar observaciones con retraso.

Gold — Marts: 4 dimensiones + 3 facts

Materialización: TABLE · 4 schemas · Consumido directamente por Power BI

DIMENSIONES

dim_especie , dim_especie_censo

Estado SCD-2 vigente del snapshot. nombre, familia, clase, endemismo, es_migratoria, CITES.

dim_area_protegida

Bounding box GPS + figuras (LIC/ZEPA/PN) + entidad gestora. Alimenta el join espacial.

dim_fecha

Una fila por fecha. Granularidad estricta: año, mes, estación. Hora en fct avistamiento.

dim_lugar, dim_ccaa

Provincia → CCAA desnormalizados. LEFT JOIN: Gibraltar/frontera queda como NULL.

FACTS

fct_avistamiento

Granularidad: 1 fila / avistamiento

SQL: JOIN espacial bounding box (BETWEEN lat_min...lat_max). QUALIFY resuelve solapamientos de áreas: Parque Nacional > ZEPA > LIC. Gold solo expone avistamientos de especies catalogadas (es_catalogada = true).

Test: unique en id_avistamiento — confirma que QUALIFY no duplica filas.

fct_censo_anual

Granularidad: 1 fila / especie+provincia+año

SQL: LAG() para variación vs año anterior. CASE para tendencia: alza/baja/estable/sin_referencia. División segura vs 0.

Test: accepted_values en tendencia — 4 ramas del CASE sin ELSE implícito.

fct_diversidad_ccaa

Granularidad: 1 fila / ccaa+año

SQL: Avistamientos con provincia y especie conocidas. Índices Shannon & Simpson calculados en SQL.

El estado de una especie puede cambiar

MITECO necesita ver el estado histórico de conservación · Snapshot SCD Tipo 2

Caso real: Lince Ibérico (*Lynx pardinus*)

2002

CR

En Peligro Crítico — <100
individuos

2015

EN

En Peligro — programa cría
en cautividad

2024

VU

Vulnerable — >1.100
individuos

¿Cuántos avistamientos había cuando era CR? → cruzamos `fct_avistamiento` con el `snapshot` por fecha

CONFIGURACIÓN DEL SNAPSHOT

```
{% snapshot especie_snapshot %}

{{
  config(
    target_schema='snapshots',
    unique_key='nombre_cientifico',
    strategy='check',
    check_cols=[
      'id_estado_iucn',
      'id_estado_espana',
      'endemismo',
      'id_cites',
      'id_tipo_migracion',
    ]
  )
}}

select
  id_especie
  , nombre_cientifico
  , nombre_comun_es
  , nombre_comun_en
  , id_familia
  , id_estado_iucn
  , id_estado_espana
  , endemismo
  , id_tipo_migracion
  , id_cites

from {{ ref('stg_mix_especie') }}

{% endsnapshot %}
```

- **dim_especie filtra dbt_valid_to IS NULL**
Gold siempre consume el estado vigente. El histórico queda accesible.
- **Snapshot sobre stg_mix__especie**
No sobre Bronze raw, el catálogo lo actualiza un biólogo editando el CSV de origen.
- **check strategy**
No necesita `updated_at` en la fuente. Compara valores de `check_cols` entre ejecuciones. No hay una Fuente fiable de `updated_at`.
- **unique_key = nombre_cientifico**
Estable globalmente. No usamos id numérico, el nombre científico es la identidad de la especie.

Pipeline, entornos y carga de datos

Python ingesta avistamientos · GitHub Actions orquesta · 3 ramas: dev / pre / pro



DBT_ENVIRONMENTS = 'DEV' | 'PRE' | 'PRO' → mismo código YAML, mismo dbt_project.yml. La variable controla en qué base de datos materializa cada capa. Cero credenciales en el repositorio.

SCRIPT PYTHON DE INGESTA

```
from snowflake.snowpark import Session
from datetime import datetime, timedelta
import random

TABLE_NAME = "OBSERVACIONES"
N_REGISTROS = random.randint(10, 20)

connection_parameters = {
    "account": "LVVQQJD-AL84024",
    "user": "RAMGAJJ2",
```

GitHub _ 3 ramas (dev/pre/main) → job dbt run + dbt test en cada PR y merge automático.

Uso de freshness en PRO: alerta si Bronze lleva +24h sin datos nuevos — evita que MITECO tome decisiones con datos obsoletos.

Resultados en Power BI

3 cuadros de mando conectados directamente a Gold en Snowflake

01 Mapa de Avistamientos

- Mapa de avistamientos desde la aplicación de iNaturalist
- Filtro por especie, clase, estado ES y área protegida
- KPI: % avistamientos fuera de zona protegida → alerta temprana
- Fuente: fct_avistamiento + dim_especie + dim_area_protegida + dim_fecha +

02 Seguimiento de Censos

- Evolución temporal de n_individuos por especie y provincia
- Tendencia: alza / baja / estable
- Comparativa entre provincias
- Fuente: fct_censo_anual + dim_especie + dim_lugar

03 Diversidad Ecológica CCAA

- Índice Shannon y Simpson por comunidad autónoma y año, que miden matemáticamente la riqueza y equidad de especies en un ecosistema
- Ranking de CCAA por riqueza de especies
- Base para justificar fondos de conservación de la UE
- Fuente: fct_diversidad_ccaa + dim_ccaa